



UNIVERSIDAD NACIONAL
AUTÓNOMA DE MÉXICO



Universidad Nacional Autónoma de México

Licenciatura en Ciencias Genómicas

Proyecto Final

Transcriptómica

Análisis transcriptómico del envejecimiento cerebral en corteza prefrontal dorsolateral de *Macaca mulatta*

Alumno: Mateo Jiménez Sotelo

Grupo: LCG22

Docente: Dr. David Valle

Semestre 2026-2

Mayo 2026

1 Introducción

1.1 Planteamiento

El envejecimiento cerebral es un proceso biológico complejo asociado con cambios progresivos en la expresión génica, la función neuronal y la susceptibilidad a enfermedades neurodegenerativas. De esta forma, diversos estudios transcriptómicos han mostrado que el envejecimiento se acompaña de alteraciones en procesos relacionados con señalización sináptica, inflamación, metabolismo energético y respuesta al estrés celular. Sin embargo, gran parte de la información disponible presenta limitaciones asociadas con diferencias fisiológicas, simplificación del modelo o variabilidad experimental.

Los primates no humanos constituyen un modelo particularmente novedoso para el estudio del envejecimiento cerebral por la conservación de múltiples características humanas neuroanatómicas y fisiológicas. En este contexto, el artículo *Multiregion transcriptomic profiling of the primate brain reveals signatures of aging and the social environment* [1] llevó a cabo un análisis transcriptómico multirregional en cerebro de *Macaca mulatta* mediante RNA-seq, en el que se evaluaron asociaciones entre **edad**, **ambiente social** y **expresión génica cerebral**. Los datos utilizados en este proyecto fueron obtenidos del *bioproject* PRJNA743289 y bajo el acceso **GSE179330** en GEO.

A pesar de los avances en los estudios del fenómeno, aún existen distintas limitaciones para comprender cómo es que el envejecimiento afecta de manera coordinada distintos procesos celulares en el cerebro de primates, y en consecuencia del macaco y, claro, del humano. En concreto, gran parte de los estudios transcriptómicos en envejecimiento cerebral se han realizado en modelos murinos o en tejidos humanos *post mortem*, los cuales presentan restricciones relacionadas con divergencia evolutiva en el primer caso, y en general con variabilidad individual y calidad del RNA recuperado en el segundo. Así, esto dificulta la distinción entre cambios asociados al envejecimiento fisiológico normal y vinculados más bien a procesos neurodegenerativos o artefactos experimentales [1].

La corteza prefrontal dorsolateral constituye una región de especial interés debido a su participación en funciones cognitivas superiores como memoria de trabajo, toma de decisiones y regulación conductual, procesos que suelen deteriorarse progresivamente con la edad. Diversos trabajos han reportado que el envejecimiento cerebral se acompaña de alteraciones en vías relacionadas con metabolismo energético, respuesta inflamatoria, comunicación sináptica y mantenimiento estructural neuronal [1]. Sin embargo, la magnitud y dirección de estos cambios puede variar considerablemente entre especies y regiones cerebrales, lo que evidencia las falencias de utilizar ratones para extrapolar los resultados a humano, al tiempo que resalta la relevancia de evaluar estos patrones específicamente en modelos de primates evolutivamente cercanos al *Homo sapiens*.

Por lo anterior, se optó por analizar y procesar datos del estudio de *bulk* RNA-seq provenientes de **corteza prefrontal dorsolateral** (dlPFC) de hembras jóvenes y adultas de *Macaca mulatta*. Se incluyen control de calidad de lecturas, limpieza de adaptadores, alineamiento contra el genoma de referencia, cuantificación de abundancias génicas y análisis de expresión diferencial mediante DESeq2. Asimismo, se hicieron análisis funcionales de enriquecimiento funcional utilizando Gene Ontology, STRING y GSEA en búsqueda de cambios de expresión asociados con envejecimiento cerebral normal en dlPFC de macaco, para evaluar si los patrones observados son consistentes con procesos biológicos previamente reportados en estudios de envejecimiento cerebral en primates.

1.2 Objetivos

Objetivo general

- Identificar cambios de expresión génica asociados con envejecimiento cerebral en corteza prefrontal dorsolateral de hembras de *Macaca mulatta* mediante un *pipeline* basado en RNA-seq.

Objetivos específicos

- Filtrar y seleccionar muestras de RNA-seq de *Macaca mulatta* correspondientes a hembras jóvenes y adultas provenientes de dIPFC.
- Evaluar y mejorar la calidad de las lecturas mediante herramientas de control de calidad y limpieza de secuencias.
- Alinear las lecturas contra el genoma de referencia Mmul_10 utilizando alineadores de RNA-seq y cuantificar abundancias génicas.
- Identificar genes diferencialmente expresados entre grupos de edad utilizando DESeq2.
- Analizar procesos biológicos y rutas enriquecidas asociadas con los genes diferencialmente expresados mediante herramientas de enriquecimiento funcional y GSEA.
- Interpretar los cambios transcriptómicos observados en el contexto biológico del envejecimiento cerebral en primates.

2 Procedimiento y resultados

Los comandos pertenecientes a alineamientos y procesamiento posterior de datos previo al análisis de expresión diferencial propiamente dicho, se simplificaron en el cuerpo del reporte para no utilizar demasiado espacio, pero se mantuvieron en el código fuente (`./JimenezSotelo_Mateo_ProyectoFinal.qmd`) en la sección de **Anexo**, al igual que los códigos de procesamiento o *parseo* de datos, para su consulta y reproducibilidad.

2.1 Datos

2.1.1 Metadatos

Se descarga el archivo de *metadata* `SraRunTable.csv` mediante [SRA Run Selector](#). Este contiene 551 muestras secuenciadas con la plataforma *Illumina NovaSeq 6000* y 31 variables asociadas a metadatos, tanto técnicos como biológicos.

Estructura: (551, 31)

Columnas:

Instrument

Illumina NovaSeq 6000 551

Name: count, dtype: int64

```
['Run', 'Assay Type', 'AvgSpotLen', 'Bases']
['BioProject', 'BioSample', 'Bytes', 'Center Name']
['Consent', 'DATASTORE filetype', 'DATASTORE provider', 'DATASTORE region']
['Experiment', 'GEO_Accession (exp)', 'Instrument', 'LibraryLayout']
['LibrarySelection', 'LibrarySource', 'Organism', 'Platform']
['ReleaseDate', 'create_date', 'version', 'Sample Name']
['SRA Study', 'AGE', 'individual_id', 'sex']
['source_name', 'tissue', 'Dominance_rank']
```

2.1.1.1 Filtrado de muestras

Con el objetivo de minimizar la heterogeneidad de los datos y maximizar la potencia estadística, se opta por un filtrado de muestras considerando aquellas correspondientes a datos de *bulk RNA-seq paired-end* (PE) con las siguientes características:

- Sexo: **Femenino**
- Edad: Grupos de **5 a 8** y de **12 a 16** años
- Tejido: **corteza prefrontal dorsolateral** (dlPFC)

```
# Solo dlPFC PE y hembras
dlpfc_f = metadata[
    (metadata["tissue"] == "dorsolateral prefrontal cortex") &
    (metadata["LibraryLayout"] == "PAIRED") &
    (metadata["sex"] == "female")
]

# Filtrado por edad
young = dlpfc_f[(dlpfc_f["AGE"] >= 5) & (dlpfc_f["AGE"] <= 8)]
old = dlpfc_f[(dlpfc_f["AGE"] >= 12) & (dlpfc_f["AGE"] <= 16)]
```

Número de muestras jóvenes únicas: 8

Número de muestras adultas únicas: 5

2.1.1.2 Selección de muestras

Tras el filtrado, se mantuvieron 13 muestras de IDs únicos (8 jóvenes y 5 adultas) derivadas de la misma plataforma y *batch*, con un *Average Spot Length* de 202 bp. De estas, se seleccionaron 10 (5 jóvenes y las 5 adultas) para análisis posteriores, con base en la cantidad de bases secuenciadas y buscando diversidad de edades. Consecuentemente, se eligen las muestras con mayor profundidad de secuenciación dentro del subconjunto sobrerrepresentado de 6 años.

```
# Se separan muestras de 6 años y las demás
young_6 = young[young["AGE"].astype(int) == 6]
young_non6 = young.drop(young_6.index)

# Se seleccionan las 2 con más bases
young_6_selected = young_6.sort_values("Bases", ascending=False).head(2)

# Conjunto joven final
young_final = pd.concat([young_non6, young_6_selected]).sort_values("AGE")
# Conjunto total final
final_samples = pd.concat([young_final, old]).sort_values("AGE")

# Columna de grupo de edad
# Young...
final_samples["AGE_group"] = "young"
# ...a menos que se vea lo contrario
final_samples.loc[final_samples["AGE"] >= 12, "AGE_group"] = "old"

# Exportar metadata filtrada y lista de SRR a descargar
os.makedirs("./data/metadata", exist_ok=True)
final_samples.to_csv("./data/metadata/selected_samples.tsv", sep="\t",
    ↪ index=False)
final_samples["Run"].to_csv("./data/metadata/srr_ids.txt", index=False,
    ↪ header=False)
```

Tabla y lista de muestras se encuentran en ./data/metadata/.

De esta manera, se descargan los siguientes SRR:

```
['SRR15024177', 'SRR15024188', 'SRR15024183', 'SRR15024186', 'SRR15024175']
['SRR15024178', 'SRR15024173', 'SRR15024174', 'SRR15024182', 'SRR15024168']
```

2.1.2 Descarga de datos

Se descargan los 10 *SRRs* seleccionados utilizando [fasterq-dump](#) de la *suite* de herramientas SRA [2], con 8 núcleos y dividiendo los archivos en pares (PE). Posteriormente, se comprimen con *gzip* para optimizar almacenamiento.

2.1.3 Calidad y limpieza de datos

Se evalúa la calidad de los fastqs descargados con [FastQC](#) [3] y se visualiza el resumen de los resultados con [MultiQC](#) [4] para decidir una estrategia de limpieza homogénea para todas las muestras mediante el script `./scripts/clean_fastqs.sh` y utilizando 4 núcleos.

Las lecturas presentan una alta calidad global, teniendo un *Phred-score* consistentemente superior a 30 y contando todas con una longitud de 101 bp (consistente con el *Average Spot Length* para PE reportado en los metadatos). Aún así, se detectó un leve contenido de adaptadores hacia los extremos 3' de las lecturas, así como un contenido de *GC* discrepante del esperado teórico y niveles moderados de secuencias sobre-representadas y duplicadas.




Figure 1: Contenido de adaptadores de las muestras previas a la limpieza

Salvo la presencia de adaptadores, estas características son esperables en datos de *bulk RNA-seq* y no repercuten negativamente en análisis posteriores [5]. Por esto, se opta limpiar adaptadores y filtrar lecturas de baja calidad, sin eliminar secuencias sobre-representadas o duplicadas.

La limpieza se lleva a cabo con [fastp](#) [6] por igual en todas las muestras, con el fin de no introducir ruido por un procesamiento heterogéneo. Se emplean detección automática de adaptadores, *trimming* de colas con baja calidad, eliminación de artefactos *polyG* y descarte de lecturas cortas (<50 bp) tras el *trimming* para evitar alineamientos inespecíficos. Esto se realiza mediante `./scripts/fastp_per_pe_sample.sh`.

Se utilizan 8 núcleos y se generan reportes individuales en formato JSON y HTML para cada muestra, almacenados en `./data/cleaned/` junto con los fastqs limpios.

```
RAW_PATH="./data/raw"
CLEANED_PATH="./data/cleaned"
mkdir -p "${CLEANED_PATH}"

conda activate fastp
```

```

for file in ${RAW_PATH}/SRR*_1.fastq.gz; do
    srr=$(basename "$file" _1.fastq.gz) # Solo el SRR

    BASE_RAW="${RAW_PATH}/${srr}"
    BASE_CLEANED="${CLEANED_PATH}/${srr}"

    # Paired End
    fastp \
        -i "${BASE_RAW}_1.fastq.gz" -I "${BASE_RAW}_2.fastq.gz" \
        -o "${BASE_CLEANED}_1.cleaned.fastq.gz" \
        -O "${BASE_CLEANED}_2.cleaned.fastq.gz" \
        --detect_adapter_for_pe --trim_poly_g \
        --cut_tail --length_required 50 --thread 8 \
        --json "${CLEANED_PATH}/${srr}.json" \
        --html "${CLEANED_PATH}/${srr}.html"
done

conda deactivate

```

Una vez limpios, se reutiliza `./scripts/clean_fastqs.sh` para evaluar la calidad de los fastqs procesados.

Se observa que la longitud de las lecturas ahora ya no es la misma a lo largo de las muestras, lo cual es esperado dado el *trimming* y la remoción de adaptadores. En cambio, el contenido de adaptadores disminuye al tiempo que el *Phred-score* se mantiene alto.




Figure 2: Contenido de adaptadores de las muestras tras la limpieza

2.2 Alineamientos

Se utilizaron los alineadores STAR [7] y HISAT2 [8], que *indexan* con base en un genoma de referencia provisto para mapear las lecturas. Dada la disponibilidad de recursos en el servidor chaac, suficientes para correr alineamientos tradicionales, y a la capacidad de estos de recuperar información posicional de las lecturas, útil para visualizaciones a nivel genómico, se optó por **no hacer pseudoalineamientos**.

Para la construcción de los índices de referencia de cada alineador, se utilizaron el genoma de referencia **Mmul_10** de *Macaca mulatta* **Release 115** (`./data/references/Macaca_mulatta.Mmul_10.dna.toplevel.fa`) y el GTF de anotación correspondiente (`./data/references/Macaca_mulatta.Mmul_10.115.gtf`). Ambos se obtuvieron de [Ensembl](#) [9].

El índice de STAR se construyó utilizando `--sjdbOverhang 100`, correspondiente a la longitud de lectura menos uno para lecturas PE de 101 bp. Este parámetro permite optimizar el mapeo de lecturas que abarcan uniones exón-exón al incorporar secuencias flanqueantes alrededor de los *splice junctions* anotados en el GTF de referencia [7].

Para el alineamiento con STAR se generaron directamente archivos BAM y conservaron las lecturas no alineadas mediante `./scripts/star_align.sh`

```
SRR=$1
DATA="./data/cleaned"
OUT="./results/aligned/star_${MODE}"
INDEX=$2
LOG_DIR="./logs/STAR"

conda activate star

INPUT="${DATA}/${SRR}_1.cleaned.fastq.gz ${DATA}/${SRR}_2.cleaned.fastq.gz"

# Incluye reads mapeados y no mapeados en el bam
/usr/bin/time -v STAR \
  --genomeDir $INDEX \
  --readFilesIn ${INPUT} \
  --readFilesCommand zcat \
  --runThreadN 8 \
  --outFileNamePrefix ${OUT}/${SRR}_ \
  --outSAMtype BAM SortedByCoordinate \
  --outSAMunmapped Within \
  2>> ${LOG_DIR}/${SRR}_time.log

conda deactivate
```


2.2.1 HISAT2

Se corrieron ambos alineadores para todas las muestras descargadas como *jobs* independientes y se guardan los archivos BAM resultantes del *output* o derivados del mismo, en el caso de HISAT2.

Debido a que ambos alineadores recuperaron un número similar de lecturas mapeadas y a que STAR, si bien computacionalmente más pesado, presentó una mayor tasa de mapeo único que HISAT2, se optó por reportar únicamente los resultados de STAR en los análisis posteriores, aunque los obtenidos con HISAT2 se mantienen disponibles para su consulta y comparación en la sección de **Anexo**.

2.3 Filtrado

Se utilizó samtools ([10]) para filtrar los archivos BAM, de forma que solo queden los alineamientos con *Mapping quality* ≥ 10 (*E-value* > 0.1), el cual es considerado el umbral estándar en *pipelines* de transcriptómica [5]. Posteriormente, los alineamientos se ordenaron por coordenada genómica e indexaron para optimizar su lectura y navegación, usando la *flag* `-f 64` para contar solo la primera lectura del par *PE*. Los archivos recibieron el sufijo `_fs` para denotar *filtered and sorted*.

2.4 Cuantificación de abundancias

Se obtuvo el conteo de lecturas por gen a partir de los BAM con featureCounts, del paquete Subread [11], y el *GTF* descargado de forma previa. Se probó el parámetro de *strandness* `-s` tanto en *forward* (1) como en *reverse* (2) para evaluar la dirección de las lecturas en la librería, pero dado que las tasas de mapeo decayeron a valores promedio de 38.38% y 37.80%, respectivamente, se optó por usar `-s 0`, sin asumir direccionalidad, consiguiendo tasas de mapeo de 71.87%. Adicionalmente, se contabilizaron solo los pares correctamente alineados, cuantificaron los fragmentos completos en lugar de lecturas individuales y resolvieron ambigüedades asignando cada fragmento al gen con el mayor solapamiento.

```
conda activate subread

# Comando con medición de tiempo y recursos
/usr/bin/time -v featureCounts \
  -o "${BAM_PATH}/counts_per_gene_${STRAND}.txt" \
  -T 8 \
  -a "${GTF}" \
  --largestOverlap \
  -p -B -s ${STRAND} \
  --countReadPairs \
  "${BAM_PATH}"/*_fs.bam \
  2>> "${LOG}"

conda deactivate
```

2.5 Matrices de conteos

Las matrices de conteos obtenidas con `featureCounts` se *reformatearon* con `./scripts/homogenize_matrixes.py` para ser compatibles con los programas de análisis de expresión diferencial, eliminando así los metadatos y ordenando las muestras en las columnas y los genes en las filas. Las matrices se guardaron en formato `tsv` en `./results/DEG/count_matrices/` y cuentan con 10 columnas, correspondientes a las 5 muestras de cada condición, y 35,432 filas, correspondientes a los genes comunes entre ambas matrices.

2.6 Anotaciones y archivos auxiliares

A partir del archivo GTF se derivaron una tabla de correspondencia entre `gene_id` y `gene_name`, útil para la identificación de genes, y una tabla de anotación de longitudes génicas, para el cálculo de métricas normalizadas. La primera tabla encontró equivalencias para 24,482 genes pues no todos los `gene_id` presentes en la matriz de conteos poseen una anotación de `gene_name` asociada en el GTF de *Ensembl* para *Macaca mulatta*. Esto posiblemente se deba a diferencias en la calidad de las anotaciones con respecto a organismos más estudiados pero no afecta los análisis posteriores, ya que los conteos se conservaron utilizando los `gene_ids`.

2.7 Condiciones

Se derivó una **tabla de condiciones** para cada muestra seleccionada a partir de los metadatos ya filtrados por sexo, tejido y edad (`./data/metadata/selected_samples.tsv`), con la condición en el formato `f_<group>` y el mismo número y orden de filas que las columnas de la matriz de conteos `./results/DEG/count_matrices/star_PE_counts.tsv`, de modo que los algoritmos de *DE* puedan asociar correctamente cada muestra con su información correspondiente [5].

Table 1: Orden de las muestras en la tabla de condiciones. Las muestras no se encuentran ordenadas por condición, sino que siguen el orden alfabético de las matrices de conteos. Los algoritmos de DE asocian cada muestra con su condición según el orden de las filas, y este se mantiene consistente, por lo que la estrategia de ordenado es indistinta.

	sample	condition
0	SRR15024168	f_old
1	SRR15024173	f_old
2	SRR15024174	f_old
3	SRR15024175	f_young
4	SRR15024177	f_young
5	SRR15024178	f_old
6	SRR15024182	f_old
7	SRR15024183	f_young
8	SRR15024186	f_young
9	SRR15024188	f_young

2.8 Expresión diferencial

El análisis de expresión diferencial se llevó a cabo en R con DESeq2 [12] y edgeR [13], utilizando las matrices de conteos y las tablas de condiciones. Se usó un diseño simple con la condición de grupo de edad como única variable. Además, se consideraron como genes diferencialmente expresados (DEG) aquellos con un *adjusted p-value* < 0.05 y un valor absoluto de *log2 fold change* > 0.5 , debido a que pruebas exploratorias previas con umbrales más estrictos apenas capturaban DEG.

Se utilizó el diseño $0 + condition$ para modelar la expresión génica sin intercepto, permitiendo comparar las condiciones de forma explícita sin establecer ninguna condición de referencia. Este diseño facilita la interpretación de los resultados al los coeficientes del modelo corresponder directamente a cada condición, en lugar de a la diferencia respecto a una condición de referencia [5,14].

El análisis se llevó a cabo mediante un *pipeline* generalizado a ambos algoritmos, homogenizando aquellas funciones reutilizables entre estos, manteniendo consistencia sintáctica entre las que no, y conservando los mismos parámetros estadísticos y criterios de significancia. Este consiste en los siguientes pasos:

1. Cargado de matriz de conteos asociada.
2. Construcción del objeto estadístico correspondiente (DESeqDataSet o DGEList).
3. Filtrado de genes con baja expresión.
4. Análisis exploratorio mediante PCA.
5. Normalización y modelado de dispersión.
6. Transformación de matrices para análisis exploratorio.
7. Ajuste de un modelo *binomial negativo* con diseño $\sim 0 + condition$
8. Contrastes entre muestras de **5 a 8** y de **12 a 16** años.
9. Extracción de los DEG.
10. Visualización de resultados mediante *volcano plots* y *heatmaps*.

Debido a que DESeq2 posee una integración más directa con las estrategias de visualización y normalización vistas durante el curso [5,14] y dado que ambos métodos recuperaron patrones globales de separación entre condiciones y DEG heterogéneos pero aún concordantes entre sí, se decidió reportar solamente sus resultados en el cuerpo del documento. Las estrategias seguidas y resultados completos de edgeR se incluyen en la sección de **Anexo** para fines de comparación y reproducibilidad.

A continuación se explican las decisiones tomadas en cada uno de los pasos del *pipeline*:

Los códigos de las funciones no incluidas se encuentran en la sección de **Anexo**

- **Filtrado de genes:** El filtrado de genes con baja expresión se hizo con la función `filterByExpr`, que es nativa de edgeR pero se utilizó en ambos casos para mantener criterios de filtrado consistentes entre los métodos [5,14].
- **PCA exploratorio:** Para el PCA, pese a que existen métodos específicos en cada algoritmo para generarlo, como `vst`, en el caso de DESeq2, se optó por utilizar de forma generalizada la función `prcomp` del paquete `stats` de R base. Esta toma la matriz de conteos transformada y normalizada y usa los mismos criterios de visualización para mantener la comparabilidad entre los métodos. El *ploteo* se realizó mediante `ggplot2`. Adicionalmente, se incluyeron solo los 500 genes con mayor varianza.

- **Contrastes** Para hacer los contrastes, se utilizó la función `makeContrasts` de `limma`. Se definió el contraste `f_old - f_young` para comparar la expresión génica entre las muestras de **5 a 8** y de **12 a 16** años [5,14].

```
create_contrasts <- function(numerator, denominator, design, variable =
  ↪ "condition") {
  # String del nombre del contraste --> "f_old_vs_f_young"
  contrast_name <- paste(numerator, "_vs_", denominator, sep = "")
  # Fórmula del contraste --> "conditionf_old-conditionf_young"
  contrast_formula <- paste(
    variable, numerator, "-", variable, denominator, sep = ""
  )
  # Matriz de contrastes
  contrasts <- makeContrasts(contrasts = contrast_formula, levels = design)
  # Renombrar columna
  colnames(contrasts) <- contrast_name

  return(contrasts)
}
```

- **Diseño experimental:** Se utilizó el objeto `DESeqDataSet`, construido a partir de la matriz de conteos, la tabla de condiciones y el diseño específico. Se aprovechó la misma función para generar también la matriz de diseño experimental.

```
create_dds <- function(counts, metadata, design_formula = ~ 0 + condition) {
  dds <- DESeqDataSetFromMatrix(countData = round(counts), colData = metadata,
  ↪ design = design_formula)
  design <- model.matrix(design_formula, data = metadata)
  return(list(dds = dds, design = design))
}
```

- **Ajuste del modelo:** `DESeq` es la función encargada de computar el modelo de DE. Por la simplicidad en cuanto a su sintaxis, se optó solo por renombrarla como `fit_deseq_model`, de forma que el flujo permanezca equivalente incluso a nivel de sintaxis entre los métodos.
- **Cálculo de TPM log2:** La normalización a TPM se deriva de la función `fpkm` de `DESeq2`, que toma como input el objeto del algoritmo usado y la tabla de anotación de longitudes génicas. El resultado es una matriz de expresión normalizada en TPM log2, utilizada para el PCA [5,14].
- **Clasificación de genes DEG:** Los genes se clasificaron como **UP**, **DOWN** o **NO** según los FDR y *Log2 fold-change* obtenidos de la tabla de resultados del análisis hecho con cualquiera de los algoritmos.

```

classify_deg <- function(res, logfc_col, padj_col, lfc = 0.5, fdr = 0.05) {
  # Inicialmente todos NO
  res$DE <- "NO"

  # Upregulated
  up <- (
    res[[logfc_col]] > lfc &
    res[[padj_col]] < fdr
  )

  # Downregulated
  down <- (
    res[[logfc_col]] < -lfc &
    res[[padj_col]] < fdr
  )

  # Quitar NAs antes
  up[is.na(up)] <- FALSE
  down[is.na(down)] <- FALSE

  # Clasificación
  res$DE[up] <- "UP"
  res$DE[down] <- "DOWN"

  return(res)
}

```

- **Volcano plot y heatmap:** Las funciones para generar los *volcano plots* y *heatmaps* son análogas a las presentadas en el curso [14], salvo por la parametrización de los nombres de las columnas de *Log2 fold-change* y FDR.

La implementación de DESeq2 recapitula los pasos previamente mencionados, por lo que no se incluye en el documento renderizado, pero permanece disponible en **esta sección** en el código fuente para su consulta y reproducibilidad.

Se obtuvo el siguiente PCA de las muestras analizadas con DESeq2 a partir de los alineamientos realizados con STAR, utilizando los 500 genes con mayor varianza:




Figure 3: PCA de las muestras analizadas con DESeq2 y alineadas con STAR, utilizando los 500 genes con mayor varianza. El análisis muestra una tenue separación entre los grupos de edad, que puede sugerir la presencia de cambios asociados al envejecimiento en corteza prefrontal dorsolateral de *Macaca mulatta* pero con un grado importante de heterogeneidad biológica entre muestras.

Se observa heterogeneidad en general entre los grupos de edades, por lo que los PCs 1 y 2 no parecen explicar en gran medida la variabilidad de la edad, sino un compilado de otros aspectos, sean técnicos o biológicos. Dado que no se cuenta con metadatos adicionales para modelar un factor de confusión que pudiera ocasionar variabilidad técnica, aunado a que el envejecimiento cerebral es un proceso gradual [1], se opta por continuar con los análisis *downstream*.




Figure 4: Gráficos de los resultados de DESeq2. A. Heatmap de los genes diferencialmente expresados más significativos obtenidos con DESeq2 a partir de alineamientos realizados con STAR. Se muestran los niveles de expresión normalizados (TPM log2 transformados a Z-score por gen) para las muestras jóvenes y adultas de *Macaca mulatta*. El patrón observado evidencia cambios transcriptómicos asociados al envejecimiento, aunque con heterogeneidad considerable entre muestras biológicas. B. Volcano plot de genes diferencialmente expresados obtenidos con DESeq2 a partir de alineamientos realizados con STAR. Se muestran los valores de log2 fold-change frente a $-\log_{10}(\text{FDR})$. Se consideraron como diferencialmente expresados aquellos genes con $|\log_2\text{FC}| > 0.5$ y $\text{FDR} < 0.05$. Los genes sobreexpresados en muestras adultas se muestran en rojo y los subexpresados en azul.

Los resultados obtenidos muestran diferencias de expresión génica a lo largo de las muestras jóvenes

y adultas, aunque con una variabilidad biológica considerable entre individuos. Aun así, los patrones observados sugieren cambios transcriptómicos moderados asociados con envejecimiento cerebral en dIPFC de *Macaca mulatta*.

2.9 Enriquecimiento funcional

GO permite interpretar listas de DEG en términos de **procesos biológicos** (BP), **funciones moleculares** (MF) y **componentes celulares** (CC), proporcionando un marco estructurado y controlado para clasificar genes y sus productos en categorías jerárquicas, facilitando así la identificación de patrones funcionales subyacentes a los cambios de expresión observados. Así, se realizaron análisis de enriquecimiento funcional basados en términos de **GO** (*Gene Ontology*) y **KEGG** con **DAVID**, la reconstrucción de las redes de interacción *proteína-proteína* mediante **STRING**, y **GSEA** (*Gene Set Enrichment Analysis*), a partir del *ranking* global [15].

Debido a que las colecciones funcionales de **MSigDB** [16] se encuentran principalmente curadas para *Homo sapiens* y no existen colecciones *Hallmark* específicas para *Macaca mulatta*, los DEG fueron convertidos a sus ortólogos humanos mediante la tabla de correspondencia entre nombres y IDs y el paquete de R *homologene* [17], aprovechando la alta conservación funcional entre primates. Se obtuvieron 10,956 ortólogos humanos, guardados en `./results/GO/mmul_human_orthologs.tsv`, con los identificadores originales de macaco y los símbolos asociados de ambas especies. De la misma forma, todos los conjuntos de genes del análisis de expresión diferencial (DEG, UP, DOWN y ALL) se exportan con los nombres comunes ortólogos humanos, y se utiliza su taxonomía para los análisis subsecuentes.

A pesar de haber obtenido 12 DEG (7 DOWN y 5 UP), se probó **DAVID** [18,19] con la intersección de cada lista con la tabla de homología, de 3 genes cada una, de forma independiente. Los genes sobreexpresados no arrojaron resultados significativos, mientras que los subexpresados arrojaron 4 términos con un *EASE threshold* de 0.1 y un *Count threshold* de 2, con *Homo sapiens* como taxonomía, el conjunto de genes presentes tras el filtrado de baja expresión como *background* y cargando únicamente la lista de los tres DEG DOWN (`./results/GO/DESeq2/star_PE_down.tsv`).

Si bien no se obtuvieron términos significativamente enriquecidos tras corrección por múltiples pruebas, posiblemente debido a los pocos DEG detectados, DAVID identificó funciones asociadas principalmente con procesos apoptóticos e inmunológicos. En particular, los genes IFI27 y TNFRSF1A estuvieron asociados consistentemente con términos relacionados con apoptosis y respuesta inmune, lo que sugiere posibles cambios transcriptómicos vinculados con estrés celular y neuroinflamación durante el envejecimiento cerebral. Posteriormente, se probó **ShinyGO** [20] con la lista de todos los DEG en aras de comparar los resultados pero no se obtuvieron enriquecimientos significativos.

Table 2: Tabla de términos enriquecidos en DAVID para genes subexpresados con DESeq2 y STAR. Se incluyen las columnas de categoría, término, p-value, Benjamini, fold enrichment y genes asociados. Los términos se ordenan por p-value de forma ascendente.

	Category	...	Genes
0	UP_KW_BIOLOGICAL_PROCESS	...	IFI27, TNFRSF1A
1	UP_SEQ_FEATURE	...	MC4R, IFI27, TNFRSF1A
2	UP_KW_BIOLOGICAL_PROCESS	...	IFI27, TNFRSF1A
3	GOTERM_BP_DIRECT	...	IFI27, TNFRSF1A

[4 rows x 6 columns]

Asimismo, [STRING](#) (*Search Tool for the Retrieval of Interacting Genes/Proteins*) fue utilizado para evaluar la existencia de módulos funcionales o redes regulatorias entre los DEG, buscando asociaciones a procesos biológicos concretos [21]. Para ello, se cargó la **lista completa de DEG**, igualmente con ortólogos humanos (`./results/G0/DESeq2/star_PE_deg_genes.tsv`), con *Homo Sapiens* como referencia. Se empleó la red completa de interacciones provista por la plataforma, que toma en cuenta asociaciones derivadas de evidencia experimental, bases de datos, coexpresión y minería de literatura [21], con un umbral de confianza medio (*medium confidence*, 0.4).




Figure 5: Red de interacción proteína–proteína generada en STRING, utilizando los genes diferencialmente expresados obtenidos mediante DESeq2. Se observaron agrupamientos funcionales asociados principalmente con procesos de mielinización y oligodendrocitos, destacando genes como MOG, MOBP, PLLP y FA2H. También se identificó un pequeño módulo relacionado con inflamación y apoptosis, incluyendo TNFRSF1A y SPATA2. Las conexiones representan asociaciones funcionales conocidas o predichas entre proteínas.




Figure 6: Gráfico de enriquecimiento funcional generado en STRING basado en anotaciones funcionales y publicaciones asociadas. Los términos enriquecidos mostraron asociaciones en mayor medida con receptores melanocortínicos y actividad relacionada con receptores de TNF. El tamaño de los puntos representa la magnitud de la señal de enriquecimiento y el color corresponde a la tasa de descubrimiento falso (FDR).

La red resultante mostró agrupamientos funcionales coherentes, como un conjunto de genes relacionados con **mielina** y **oligodendrocitos**, que podrían implicar alteraciones sutiles asociadas en estas durante el envejecimiento. Adicionalmente, algunos genes se asociaron con procesos inflamatorios y apoptóticos. Asimismo, los términos enriquecidos obtenidos se relacionaron con señalización mediada por receptores melanocortínicos y funciones inmunes asociadas a receptores de TNF. Pese al número de genes diferencialmente expresados, ambos análisis mostraron consistencia entre sí mismos.

Dado que la cantidad de genes diferencialmente expresados en general era limitada, se realizó un análisis de **GSEA** (*Gene Set Enrichment Analysis*) con el ranking global de genes ordenados por la columna *res* de DESeq2, derivado del *estadístico de Wald*, que recapitula sobre la dirección y magnitud de expresión de los genes [22]. El análisis se llevó a cabo en modo *preranked*, utilizando las colecciones de conjuntos de genes *Hallmark* de **MSigDB** de *homo sapiens* [16] y haciendo 1,000 permutaciones con conjuntos de entre 15 y 500 genes.




Figure 7: Resultados representativos del análisis GSEA utilizando colecciones Hallmark de MSigDB. A. Enriquecimiento negativo del conjunto HALLMARK_EPITHELIAL_MESENCHYMAL_TRANSITION, indicando una acumulación coordinada de genes asociados a remodelación tisular hacia el extremo correspondiente a las muestras jóvenes. B. Enriquecimiento negativo del conjunto HALLMARK_APOPTOSIS, sugiriendo una mayor representación relativa de genes relacionados con apoptosis y respuesta a estrés celular en muestras jóvenes. C. Enriquecimiento negativo del conjunto HALLMARK_INTERFERON_ALPHA_RESPONSE, consistente con activación coordinada de genes asociados a señalización inmune e interferón. D. Relación entre el normalized enrichment score (NES) y la significancia estadística de los conjuntos Hallmark evaluados. Los puntos resaltados corresponden a conjuntos significativamente enriquecidos.




Figure 8: Resumen global de los resultados de GSEA para colecciones Hallmark. El eje X muestra el normalized enrichment score (NES) de cada conjunto génico y el eje Y los procesos biológicos evaluados. Los valores negativos indican enriquecimiento relativo hacia genes más altamente expresados en muestras jóvenes, mientras que los valores positivos indican enriquecimiento hacia muestras viejas. Los colores representan la significancia estadística corregida por FDR. Destacan procesos relacionados con transición epitelio-mesénquima, respuesta inflamatoria, señalización por interferón, apoptosis y angiogénesis.

Se obtuvo un enriquecimiento significativo de vías relacionadas con respuesta inflamatoria, señalización por interferón, apoptosis, angiogénesis y transición epitelio-mesénquima (EMT). En general, estos conjuntos presentaron valores negativos de NES, indicador de un mayor representación relativa hacia genes más expresados en muestras jóvenes.

3 Discusión

El análisis realizado posibilitó la identificación de cambios de expresión génica asociados con envejecimiento cerebral en corteza prefrontal dorsolateral de *Macaca mulatta*. Aunque el número de genes diferencialmente expresados fue relativamente reducido bajo los criterios de significancia empleados, los resultados obtenidos con análisis sobre el *ranking* global muestran tendencias biológicamente consistentes con procesos reportados previamente durante envejecimiento cerebral normal.

Los genes diferencialmente expresados y los análisis de enriquecimiento sugieren alteraciones relacionadas con señalización neuronal, respuesta al estrés y procesos inmunológicos. En particular, los análisis funcionales apuntan hacia una disminución de procesos asociados con actividad sináptica y regulación neuronal, así como cambios en rutas relacionadas con inflamación y respuesta celular. Estos resultados

son congruentes con observaciones reportadas en el artículo original [1], donde el envejecimiento cerebral en macacos se asoció con disminución de genes relacionados con función neuronal y aumento de procesos asociados con respuesta inmune e inflamación.

El agrupamiento observado en el *heatmap* sugiere, además, la existencia de perfiles transcriptómicos parcialmente diferenciados entre muestras jóvenes y adultas. Esto indica que, aún con un tamaño de muestra limitado, es posible recuperar señales biológicas asociadas con la edad. De forma similar, el análisis de GSEA mostró enriquecimiento de conjuntos génicos relacionados con envejecimiento, metabolismo y respuesta celular, reforzando la consistencia biológica de los resultados obtenidos.

Inevitablemente, este trabajo presenta varias limitaciones. En primer lugar, el tamaño de muestra fue reducido, lo que disminuye la potencia estadística y probablemente limita la detección de DEG. Asimismo, el análisis se restringió a hembras y a una única región cerebral, por lo que los resultados no necesariamente representan procesos globales de envejecimiento cerebral. Aunado, al tratarse de datos de *bulk* RNA-seq, los cambios observados reflejan señales promedio de múltiples tipos celulares y no permiten distinguir contribuciones específicas de poblaciones neuronales o gliales concretas.

A pesar de estas limitaciones, el pipeline implementado permitió reproducir múltiples tendencias biológicas descritas previamente para envejecimiento cerebral en primates, mostrando que los análisis de RNA-seq constituyen una herramienta útil para estudiar procesos moleculares complejos asociados con envejecimiento y neurobiología, junto con la importancia de considerar la heterogeneidad biológica y las limitaciones inherentes a los propios datos disponibles al interpretar los resultados. Más aún, a esto le subyace la necesidad de la correcta selección de datos al llevar a cabo análisis que precisen de significancia estadística y, sobre todo, el sesgo de estudios que existe hacia organismos modelo más estudiados, lo que limita la disponibilidad de datos y herramientas para estudiar procesos biológicos en especies no tan comunes y dificulta, por tanto, los hallazgos de procesos moleculares con implicaciones clínicas potenciales.

4 Conclusiones

Los resultados obtenidos permitieron identificar cambios transcriptómicos asociados con envejecimiento cerebral en corteza prefrontal dorsolateral, particularmente en procesos relacionados con señalización neuronal, respuesta inmune y estrés celular. Aunque el número de genes diferencialmente expresados fue limitado, los patrones observados fueron consistentes entre sí mismos y con hallazgos reportados previamente en estudios de envejecimiento cerebral en primates.

El uso de herramientas como DESeq2, GSEA y análisis de enriquecimiento funcional permitió interpretar los cambios de expresión génica dentro de un contexto biológico amplio, resaltando la utilidad de los enfoques transcriptómicos para estudiar mecanismos moleculares asociados con envejecimiento cerebral y demostrando que el análisis bioinformático de datos de RNA-seq permite recuperar señales biológicamente relevantes incluso a partir de subconjuntos reducidos y heterogéneos de muestras. Así, si bien constituye una aproximación útil para explorar procesos de envejecimiento y regulación génica en sistemas complejos, exhibe las limitaciones de estos estudios cuando se cuenta con un número reducido de muestras, los patrones de expresión no son tan pronunciados, se carece de un universo extenso de metadatos para modelar factores de confusión o se trabaja con especies no modelo con anotaciones menos completas.

5 Referencias

1. Kenneth L. Chiou, Alex R. DeCasien, Katherina P. Rees, Camille Testard, Cailyn H. Spurrell, Aishwarya A. Gogate, Hannah A. Pliner, Sébastien Tremblay, Arianne Mercer, Connor J. Whalen, Josué E. Negrón-Del Valle, Mareike C. Janiak, Samuel E. Bauman Surratt, Olga González, Nicole R. Compo, Michala K. Stock, Angelina V. Ruiz-Lambides, Melween I. Martínez, Melissa A. Wilson, Amanda D. Melin, Susan C. Antón, Christopher S. Walker, Jérôme Sallet, Jason M. Newbern, Lea M. Starita, Jay Shendure, James P. Higham, Lauren J. N. Brent, Michael J. Montague, Michael L. Platt, Noah Snyder-Mackler. Multiregion transcriptomic profiling of the primate brain reveals signatures of aging and the social environment. *Nature Neuroscience*. 2022 Nov;25(12):1714–23. doi:[10.1038/s41593-022-01197-0](https://doi.org/10.1038/s41593-022-01197-0)
2. NCBI Sequence Read Archive. SRA toolkit [Internet]. 2026. Available from: <https://github.com/ncbi/sra-tools>
3. Simon Andrews. FastQC: A quality control tool for high throughput sequence data [Internet]. 2010. Available from: <https://www.bioinformatics.babraham.ac.uk/projects/fastqc/>
4. Philip Ewels, Måns Magnusson, Sverker Lundin, Max Käller. MultiQC: summarize analysis results for multiple tools and samples in a single report. *Bioinformatics*. 2016 Jun;32(19):3047–8. doi:[10.1093/bioinformatics/btw354](https://doi.org/10.1093/bioinformatics/btw354)
5. Ricardo Valle García. Curso de transcriptómica 2026: Anotación funcional y enriquecimiento biológico. 2026.
6. Shifu Chen, Yanqing Zhou, Yaru Chen, Jia Gu. fastp: an ultra-fast all-in-one FASTQ preprocessor. *Bioinformatics*. 2018 Jul;34(17):i884–90. doi:[10.1093/bioinformatics/bty560](https://doi.org/10.1093/bioinformatics/bty560)
7. Alexander Dobin, Carrie A. Davis, Felix Schlesinger, Jorg Drenkow, Chris Zaleski, Sonali Jha, Philippe Batut, Mark Chaisson, Thomas R. Gingeras. STAR: Ultrafast universal RNA-seq aligner. *Bioinformatics*. 2013;29(1):15–21. doi:[10.1093/bioinformatics/bts635](https://doi.org/10.1093/bioinformatics/bts635)
8. Daehwan Kim, Joseph M. Paggi, Chanhee Park, Christopher Bennett, Steven L. Salzberg. Graph-based genome alignment and genotyping with HISAT2 and HISAT-genotype. *Nature Biotechnology*. 2019;37(8):907–15. doi:[10.1038/s41587-019-0201-4](https://doi.org/10.1038/s41587-019-0201-4)
9. Andrew D. Yates, others. Ensembl 2025. *Nucleic Acids Research*. 2025;53(D1):DXXX–. doi:[10.1093/nar/gkae1071](https://doi.org/10.1093/nar/gkae1071)
10. Heng Li, Bob Handsaker, Alec Wysoker, Tim Fennell, Jue Ruan, Nils Homer, Gabor Marth, Goncalo Abecasis, Richard Durbin, Genome Project Data Processing Subgroup. The Sequence Alignment/Map format and SAMtools. *Bioinformatics*. 2009 Jun;25(16):2078–9. doi:[10.1093/bioinformatics/btp352](https://doi.org/10.1093/bioinformatics/btp352)

11. Yang Liao, Gordon K. Smyth, Wei Shi. featureCounts: an efficient general purpose program for assigning sequence reads to genomic features. *Bioinformatics*. 2013 Nov;30(7):923–30. doi:[10.1093/bioinformatics/btt656](https://doi.org/10.1093/bioinformatics/btt656)
12. Michael I. Love, Wolfgang Huber, Simon Anders. Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2. *Genome Biology*. 2014;15(12):550. doi:[10.1186/s13059-014-0550-8](https://doi.org/10.1186/s13059-014-0550-8)
13. Mark D. Robinson, Davis J. McCarthy, Gordon K. Smyth. edgeR: A bioconductor package for differential expression analysis of digital gene expression data. *Bioinformatics*. 2010;26(1):139–40. doi:[10.1093/bioinformatics/btp616](https://doi.org/10.1093/bioinformatics/btp616)
14. David Valle-Garcia. Clase 8 - análisis de expresión diferencial con DESeq2. Material de curso en HTML generado con Quarto; 2026.
15. Ricardo Valle García. Notas de anotación funcional para RNA-seq. 2026.
16. Arthur Liberzon, Chet Birger, Helga Thorvaldsdóttir, Mahmoud Ghandi, Jill P. Mesirov, Pablo Tamayo. The Molecular Signatures Database Hallmark Gene Set Collection. *Cell Systems*. 2015 Dec;1(6):417–25. doi:[10.1016/j.cels.2015.12.004](https://doi.org/10.1016/j.cels.2015.12.004)
17. Ogan Mancarci. homologene: Quick Access to Homologene and Gene Annotation Updates [Internet]. 2018. Available from: <https://doi.org/10.32614/cran.package.homologene> doi:[10.32614/cran.package.homologene](https://doi.org/10.32614/cran.package.homologene)
18. Da Wei Huang, Brad T. Sherman, Richard A. Lempicki. Systematic and integrative analysis of large gene lists using DAVID bioinformatics resources. *Nature Protocols*. 2009;4(1):44–57. doi:[10.1038/nprot.2008.211](https://doi.org/10.1038/nprot.2008.211)
19. Brad T. Sherman, Ming Hao, Jiao Qiu, Xiaoli Jiao, Michael W. Baseler, H. Clifford Lane, Tomozumi Imamichi, Wenyi Chang. DAVID: A web server for functional enrichment analysis and functional annotation of gene lists (2021 update). *Nucleic Acids Research*. 2022;50(W1):W216–21. doi:[10.1093/nar/gkac194](https://doi.org/10.1093/nar/gkac194)
20. Steven Xijin Ge, Dongmin Jung, Runan Yao. ShinyGO: a graphical gene-set enrichment tool for animals and plants. *Bioinformatics*. 2019 Dec;36(8):2628–9. doi:[10.1093/bioinformatics/btz931](https://doi.org/10.1093/bioinformatics/btz931)
21. Damian Szklarczyk, Rebecca Kirsch, Mikaela Koutrouli, Katerina Nastou, Farrokh Mehryary, Radja Hachilif, Annika L. Gable, Tao Fang, Nadezhda T. Doncheva, Sampo Pyysalo, others. The STRING database in 2023: Protein–protein association networks and functional enrichment analyses for any sequenced genome of interest. *Nucleic Acids Research*. 2023;51(D1):D638–46. doi:[10.1093/nar/gkac1000](https://doi.org/10.1093/nar/gkac1000)

22. Aravind Subramanian, Pablo Tamayo, Vamsi K. Mootha, Sayan Mukherjee, Benjamin L. Ebert, Michael A. Gillette, Amanda Paulovich, Scott L. Pomeroy, Todd R. Golub, Eric S. Lander, Jill P. Mesirov. Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles. *Proceedings of the National Academy of Sciences*. 2005;102(43):15545–50. doi:[10.1073/pnas.0506580102](https://doi.org/10.1073/pnas.0506580102)
23. Rob Patro, Geet Duggal, Michael I. Love, Rafael A. Irizarry, Carl Kingsford. Salmon provides fast and bias-aware quantification of transcript expression. *Nature Methods*. 2017;14(4):417–9. doi:[10.1038/nmeth.4197](https://doi.org/10.1038/nmeth.4197)
24. Oscar Rueda, Bernard Pereira. Differential expression analysis using edgeR. University of Cambridge; 2015.

6 Reproducibilidad

6.1 Entorno de ejecución

- Sistema operativo local: Linux Arch (6.19.8-arch1-1)
- Shell utilizada: zsh 5.9
- Servidor de cómputo: chaac
- Gestor de ambientes: conda 2.5.0
- Documento generado mediante Quarto 1.8.27 con salida PDF vía LaTeX

6.2 Versiones de software

- Python 3.11.14
- R 4.5.3
- FastQC 0.12.1
- MultiQC 1.33
- fastp 0.24.1
- STAR 2.7.11b
- HISAT2 2.2.1
- samtools 1.21
- featureCounts/Subread 2.0.8

6.3 Datos utilizados

- Bioproyecto: PRJNA743289
- GEO: GSE179330
- Organismo: *Macaca mulatta*
- Genoma de referencia: Mmul_10
- Anotación génica: Ensembl Release 115

6.4 Organización del proyecto

- ./data/: datos crudos, referencias y archivos FASTQ procesados
- ./scripts/: automatización y scripts auxiliares
- ./results/: alineamientos, matrices de conteos, análisis diferenciales y enriquecimiento funcional
- ./docs/: portada, bibliografía y archivos auxiliares de renderizado

6.5 Pipeline general

1. Descarga de datos mediante `fasterq-dump`
2. Control de calidad con FastQC y MultiQC
3. Limpieza y filtrado de lecturas con `fastp`
4. Alineamiento contra el genoma de referencia mediante STAR y HISAT2
5. Filtrado, ordenamiento e indexado de BAMs utilizando `samtools`
6. Cuantificación de abundancias génicas mediante `featureCounts`
7. Análisis de expresión diferencial con DESeq2
8. Análisis funcional mediante GO, STRING y GSEA

Adicionalmente, los parámetros relevantes utilizados durante el análisis fueron especificados explícitamente dentro del documento para facilitar la reproducibilidad completa del pipeline.

7 Anexo

7.1 Filtrado de muestras

Table 3: Tabla de muestras del grupo de edad joven (5-8 años) antes de la selección final. Se muestran las 10 muestras filtradas, ordenadas por edad y con información relevante para la selección final.

	Run	AGE	individual_id	Bases
295	SRR15024177	5.08	5N1	5056801744
300	SRR15024188	5.13	9N0	4476837120
298	SRR15024180	6.13	7L0	4236270472
299	SRR15024181	6.14	7L7	4413674346
545	SRR15024183	6.16	8K7	4486984186
549	SRR15024187	6.94	9I7	3663353426
548	SRR15024186	6.97	9I5	4968542086
543	SRR15024175	7.27	4J3	5486909234

Table 4: Tabla de muestras del grupo de edad adulto (12-16 años) antes de la selección final. Se muestran las 5 muestras filtradas, ordenadas por edad y con información relevante para la selección final.

	Run	AGE	individual_id	Bases
296	SRR15024178	12.03	65Z	4295485358
293	SRR15024173	12.07	3A9	4712462444
542	SRR15024174	12.96	48V	5149769012
544	SRR15024182	14.10	80S	5789284246
540	SRR15024168	14.91	20S	5799210526

7.2 Manejo de logs

Se implementó el manejo de *logs* para los scripts de descarga de SRR y limpieza de datos con el fin de facilitar la trazabilidad de los procesos. No se muestran la implementación ni el despliegue de los mismos en los *chunks* de código para evitar saturar el documento, pero se encuentran disponibles en `./scripts/` y `./logs/`, respectivamente así como en esta sección en el documento fuente (`./JimenezSotelo_Mateo_ProyectoFinal.qmd`).

7.3 Descarga de datos

Tamaño tras comprimir de los archivos fastq crudos resultantes:

```

1.4G ./data/raw/SRR15024168_1.fastq.gz
1.5G ./data/raw/SRR15024168_2.fastq.gz
1.2G ./data/raw/SRR15024173_1.fastq.gz
1.3G ./data/raw/SRR15024173_2.fastq.gz
1.3G ./data/raw/SRR15024174_1.fastq.gz
1.4G ./data/raw/SRR15024174_2.fastq.gz
1.4G ./data/raw/SRR15024175_1.fastq.gz
1.4G ./data/raw/SRR15024175_2.fastq.gz
1.3G ./data/raw/SRR15024177_1.fastq.gz
1.3G ./data/raw/SRR15024177_2.fastq.gz
1.1G ./data/raw/SRR15024178_1.fastq.gz
1.1G ./data/raw/SRR15024178_2.fastq.gz
1.4G ./data/raw/SRR15024182_1.fastq.gz
1.5G ./data/raw/SRR15024182_2.fastq.gz
1.1G ./data/raw/SRR15024183_1.fastq.gz
1.2G ./data/raw/SRR15024183_2.fastq.gz
1.2G ./data/raw/SRR15024186_1.fastq.gz
1.3G ./data/raw/SRR15024186_2.fastq.gz
1.1G ./data/raw/SRR15024188_1.fastq.gz
1.2G ./data/raw/SRR15024188_2.fastq.gz

```

7.4 Limpieza de datos

Sample Name	Dups	GC	Seqs
SRR15024168_1	54.3%	50.0%	28.7M
SRR15024168_2	49.5%	50.0%	28.7M
SRR15024173_1	62.6%	51.0%	23.3M
SRR15024173_2	56.9%	51.0%	23.3M
SRR15024174_1	57.4%	52.0%	25.5M
SRR15024174_2	52.3%	52.0%	25.5M
SRR15024175_1	47.9%	51.0%	27.2M
SRR15024175_2	44.6%	51.0%	27.2M
SRR15024177_1	50.7%	50.0%	25.0M
SRR15024177_2	46.6%	50.0%	25.0M
SRR15024178_1	46.7%	50.0%	21.3M
SRR15024178_2	43.3%	50.0%	21.3M
SRR15024182_1	49.3%	51.0%	28.7M
SRR15024182_2	45.4%	51.0%	28.7M
SRR15024183_1	44.7%	51.0%	22.2M
SRR15024183_2	40.9%	51.0%	22.2M
SRR15024186_1	45.1%	51.0%	24.6M
SRR15024186_2	41.8%	51.0%	24.6M
SRR15024188_1	43.5%	50.0%	22.2M
SRR15024188_2	40.6%	51.0%	22.2M

Figure 9: Estadísticas generales de calidad de datos crudos

Sample Name	Dups	GC	Seqs
SRR15024168.1	54.2%	50.0%	28.1 M
SRR15024168.2	50.3%	50.0%	28.1 M
SRR15024173.1	62.5%	51.0%	22.7 M
SRR15024173.2	58.0%	51.0%	22.7 M
SRR15024174.1	57.4%	52.0%	24.9 M
SRR15024174.2	53.3%	52.0%	24.9 M
SRR15024175.1	47.8%	51.0%	26.5 M
SRR15024175.2	45.2%	50.0%	26.5 M
SRR15024177.1	50.5%	50.0%	24.4 M
SRR15024177.2	47.4%	50.0%	24.4 M
SRR15024178.1	46.7%	50.0%	20.8 M
SRR15024178.2	43.9%	50.0%	20.8 M
SRR15024182.1	49.1%	51.0%	28.0 M
SRR15024182.2	45.9%	51.0%	28.0 M
SRR15024183.1	44.4%	50.0%	21.7 M
SRR15024183.2	41.4%	50.0%	21.7 M
SRR15024186.1	44.8%	51.0%	24.1 M
SRR15024186.2	42.2%	51.0%	24.1 M
SRR15024188.1	43.2%	50.0%	21.6 M
SRR15024188.2	40.9%	50.0%	21.6 M

Figure 10: Estadísticas generales de calidad de datos limpios




Figure 11: Heatmap de estado de calidad de datos crudos




Figure 12: Heatmap de estado de calidad de datos limpios




Figure 13: Distribución de longitud de secuencias de datos limpios. Las muestras pasan de medir todas 101bp a longitudes variables menores a esta tras la limpieza. No se cuenta con la gráfica análoga de las muestras crudas dadas las longitudes iguales



Figure 14: Calidad media de los datos crudos. Se muestra una calidad alta, con Phred-scores mayoritaria-mente por encima de 35




Figure 15: Calidad media de los datos limpios. Se mantiene una calidad alta, con Phred-scores igualmente por encima de 35

7.5 Alineamientos

Se construyó también el índice de Salmon pero, con base en las comparaciones realizadas en las tareas del curso y tras obtener tasas de mapeo altas en STAR y HISAT2 (alineamientos hechos simultáneamente), se optó por no realizar *pseudoalineamientos*. Este requería, en lugar del genoma de referencia, un índice construido a partir de las secuencias de transcritos, también obtenidas de Ensembl [9,23].

Se usó el siguiente *script* para la conversión de SAM a BAM de los resultados de HISAT2

Se generó un *dataframe* con las estadísticas de alineamiento de ambos programas con el *script* `./scripts/stats_table.py`, a partir de una estrategia híbrida de extracción de los resúmenes de

alineamiento (*.out para STAR y *.txt para HISAT2), para extraer las tasas de mapeo único, y de los BAMs con Samtools flagstat, para las métricas básicas restantes [10].

7.5.1 STAR

./scripts/star_align.sh

7.5.2 Hisat2

HISAT2 no tiene un entorno de *Conda* propio.

Se utilizó ./scripts/hisat2_align.sh.

7.5.3 flagstat y estadísticas de alineamiento

Table 5: Muestras jóvenes seleccionadas para el análisis transcriptómico y sus estadísticas de alineamiento.

	Sample	Tool	... Properly paired (%)	Unique mapping (%)
0	SRR15024173	HISAT2	...	88.84
1	SRR15024168	HISAT2	...	89.67
2	SRR15024174	HISAT2	...	88.89
3	SRR15024175	HISAT2	...	89.41
4	SRR15024178	HISAT2	...	88.90
5	SRR15024177	HISAT2	...	89.30
6	SRR15024183	HISAT2	...	90.23
7	SRR15024182	HISAT2	...	89.99
8	SRR15024186	HISAT2	...	90.60
9	SRR15024188	HISAT2	...	89.61
10	SRR15024168	STAR	...	95.22
11	SRR15024173	STAR	...	94.79
12	SRR15024174	STAR	...	94.77
13	SRR15024175	STAR	...	94.93
14	SRR15024177	STAR	...	95.02
15	SRR15024178	STAR	...	94.20
16	SRR15024182	STAR	...	95.46
17	SRR15024183	STAR	...	95.62
18	SRR15024188	STAR	...	95.22
19	SRR15024186	STAR	...	96.14

[20 rows x 11 columns]

7.6 FeatureCounts

```
SCRIPT="./scripts/make_featureCounts.sh"
ALIGN_PATH="./results/aligned"
GTF="./data/references/Macaca_mulatta.Mmul_10.115.gtf"

# Barrido de tipo de librería
for i in {0..2}; do
    qsub "$SCRIPT" "${ALIGN_PATH}/hisat2_PE" "$GTF" "$i"
    qsub "$SCRIPT" "${ALIGN_PATH}/star_PE" "$GTF" "$i"
done
```

Resultados:

```
path = "./results/aligned/hisat2_PE/"

def load_fc_counts(path) -> pd.DataFrame:
    return pd.read_csv(path, sep="\t", comment="#", engine="python")

fc_dfs = {}
# Leer cada archivo de conteos
for strand in range(3): # 0, 1, 2 para los tipos de strand
    for aligner in ["hisat2_PE", "star_PE"]:
        fc_dfs[f"fc_{aligner}_{strand}"] = (df :=
↪ load_fc_counts(f"./results/aligned/{aligner}/counts_per_gene_{strand}.txt"))
        print(f"{aligner} y strandness {strand}:")
        print(df.head())
```

hisat2_PE y strandness 0:

	Geneid	...	./results/aligned/hisat2_PE/SRR15024188.fs.bam
0	ENSMMUG000000023296	...	0
1	ENSMMUG000000036181	...	1
2	ENSMMUG00000000634	...	622
3	ENSMMUG000000037875	...	238
4	ENSMMUG00000000632	...	2003

[5 rows x 16 columns]

star_PE y strandness 0:

	Geneid	...	./results/aligned/star_PE/SRR15024188_Aligned.sortedByCoord.out
0	ENSMMUG000000023296	...	0
1	ENSMMUG000000036181	...	1
2	ENSMMUG00000000634	...	673

3	ENSMMUG000000037875	...	252
4	ENSMMUG00000000632	...	2083

[5 rows x 16 columns]

hisat2_PE y strandness 1:

	Geneid	...	./results/aligned/hisat2_PE/SRR15024188.fs.bam	
0	ENSMMUG000000023296	...		0
1	ENSMMUG000000036181	...		1
2	ENSMMUG00000000634	...		557
3	ENSMMUG000000037875	...		331
4	ENSMMUG00000000632	...		1056

[5 rows x 16 columns]

star_PE y strandness 1:

	Geneid	...	./results/aligned/star_PE/SRR15024188_Aligned.sortedByCoord.out	
0	ENSMMUG000000023296	...		0
1	ENSMMUG000000036181	...		1
2	ENSMMUG00000000634	...		586
3	ENSMMUG000000037875	...		337
4	ENSMMUG00000000632	...		1079

[5 rows x 16 columns]

hisat2_PE y strandness 2:

	Geneid	...	./results/aligned/hisat2_PE/SRR15024188.fs.bam	
0	ENSMMUG000000023296	...		0
1	ENSMMUG000000036181	...		0
2	ENSMMUG00000000634	...		598
3	ENSMMUG000000037875	...		336
4	ENSMMUG00000000632	...		973

[5 rows x 16 columns]

star_PE y strandness 2:

	Geneid	...	./results/aligned/star_PE/SRR15024188_Aligned.sortedByCoord.out	
0	ENSMMUG000000023296	...		0
1	ENSMMUG000000036181	...		0
2	ENSMMUG00000000634	...		630
3	ENSMMUG000000037875	...		348
4	ENSMMUG00000000632	...		1004

[5 rows x 16 columns]

Tasas promedio de mapeo tras featureCounts, por tipo de alineador y strandness:

Table 6: Tasas de mapeo promedio obtenidas con featureCounts para cada alineador y tipo de strandness.

	aligner	strandness	mean_percentage
0	hisat2_PE	0	66.87
1	hisat2_PE	1	36.17
2	hisat2_PE	2	35.61
3	star_PE	0	71.87
4	star_PE	1	38.38
5	star_PE	2	37.80

Genes comunes entre las matrices: 35432

hisat2_PE: (35432, 10)

star_PE: (35432, 10)

7.7 Anotaciones y archivos auxiliares

Script de generación de tabla de correspondencia entre gene_id y gene_name a partir del GTF:

Table 7: Tabla de correspondencia antes de quitar duplicados entre gene_id y gene_name, derivada del GTF. Se muestran los primeros registros.

Antes de quitar duplicados: (24482, 2)

	Geneid	Gene_name
0	ENSMMUG000000023296	PGBD2
1	ENSMMUG000000036181	U6
2	ENSMMUG00000000634	ZNF692
3	ENSMMUG000000037875	ZNF672
4	ENSMMUG00000000632	SH3BP5L

Table 8: Tabla de correspondencia después de quitar duplicados entre `gene_id` y `gene_name`, derivada del GTF. Se muestran los primeros registros, con 24,482 filas.

Después de quitar duplicados: (24482, 2)

	Geneid	Gene_name
0	ENSMMUG000000023296	PGBD2
1	ENSMMUG000000036181	U6
2	ENSMMUG000000000634	ZNF692
3	ENSMMUG000000037875	ZNF672
4	ENSMMUG000000000632	SH3BP5L

Para la tabla de longitudes génicas se utilizan las longitudes reportadas por `featureCounts` para cada gen (`Geneid`) en la columna `Length` de sus tablas de conteo, que corresponden a su vez a la suma de las longitudes de los exones de cada gen en la anotación del GTF [11]:

Dado que el GTF es el mismo para ambos alineamientos, se utiliza el archivo de `featureCounts` de star (`./results/aligned/star/counts_per_gene.txt`).

La generación de ortólogos se realiza a través de la función `homologene` del paquete `homologene` de Bioconductor, que consulta la base de datos de HomoloGene para encontrar genes ortólogos entre especies [17]. Se parte de los símbolos génicos (`gene_name`) presentes en las matrices de conteos, se convierten a símbolos humanos utilizando `org.Hs.eg.db` y luego se obtiene la tabla de correspondencia entre los símbolos de macaco y humano. Finalmente, se exporta esta tabla para su uso en el análisis de enriquecimiento funcional.

7.8 Tabla de condiciones

Se utiliza nuevamente la matriz de `star_PE` para obtener el orden de las muestras, dado que este es consistente a lo largo de todas las matrices.

7.9 Pipeline de expresión diferencial

Función	Propósito	Algoritmo
<code>load_dataset()</code>	Cargar matrices de conteos y metadatos experimentales.	General
<code>filter_low_expression()</code>	Filtrar genes con baja expresión utilizando <code>filterByExpr</code> .	General
<code>pca_plot()</code>	Realizar PCA exploratorio sobre matrices normalizadas y generar visualizaciones.	General
<code>create_contrasts()</code>	Construir matrices de contraste para comparar condiciones experimentales.	General
<code>classify_deg()</code>	Clasificar genes diferencialmente expresados como UP, DOWN o NO según $\log_2FC$ y FDR dados.	General
<code>plot_volcano()</code>	Generar <i>volcano plots</i> de resultados de expresión diferencial.	General
<code>plot_heatmap()</code>	Generar <i>heatmaps</i> de genes diferencialmente expresados más significativos.	General
<code>export_results()</code>	Exportar listas de genes y matrices normalizadas para análisis funcionales posteriores.	General
<code>create_dds()</code>	Construir objetos <code>DESeqDataSet</code> y generar la matriz de diseño experimental.	DESeq2
<code>fit_deseq_model()</code>	Ajustar el modelo estadístico de expresión diferencial mediante <code>DESeq</code> .	DESeq2
<code>compute_tpm()</code>	Calcular matrices de expresión normalizadas en TPM $\log_2$ para visualización y análisis exploratorios.	DESeq2
<code>create_dgeList()</code>	Construir objetos <code>DGEList</code> , normalizar bibliotecas con TMM y estimar dispersión.	edgeR
<code>fit_edger_model()</code>	Ajustar modelos lineales generalizados mediante <code>glmQLFit</code> .	edgeR
<code>extract_edger_results()</code>	Obtener tablas de resultados de expresión diferencial a partir de contrastes estadísticos.	edgeR
<code>compute_logcpm()</code>	Calcular matrices de expresión normalizada en logCPM para visualización y análisis exploratorios.	edgeR

Figure 16: Funciones implementadas en el pipeline de análisis transcriptómico, incluyendo utilidades generales de preprocesamiento, visualización y exportación, así como funciones específicas para análisis de expresión diferencial con DESeq2 y edgeR.

7.9.1 Carga de datos

7.9.2 Funciones generales

Se definen las funciones reutilizables para ambos algoritmos, buscando máxima comparabilidad entre los métodos:

7.9.2.1 Cargado de matriz

7.9.2.2 Filtrado de genes

7.9.2.3 PCA exploratorio

Mostrando la varianza de todos los genes:

Mostrando la varianza del top n genes que más presentan:

7.9.2.4 Volcano plot y heatmap

7.9.3 Exportar resultados

7.9.4 Funciones de DESeq2

En general, las funciones de DESeq2 son de alto nivel. Aún así, se definieron funciones específicas por simplicidad y en aras de mantener un flujo de análisis homogéneo entre los métodos.

7.9.4.1 Ajuste del modelo

7.9.4.2 Normalización a TPM

7.9.5 edgeR

7.9.5.1 DGEList

En edgeR se usa DGEList, que se crea a partir de la matriz de conteos, los metadatos y el diseño experimental. De acuerdo al flujo, se define una función específica para su construcción [13,24]. Asimismo, se integran en la función los procesos de normalización de bibliotecas mediante TMM (Trimmed Mean of M-values) con calcNormFactors, para corregir diferencias de composición y profundidad; y la estimación de dispersión con estimateDisp, para modelar la sobredispersión de los conteos. Estos, en contraposición con DESeq2, se realizan de forma explícita [13].

7.9.5.2 Ajuste de modelo

El ajuste del modelo de DE se realiza con la función glmQLFit, renombrada fit_edger_model. Esta ajusta un modelo lineal generalizado con el método *quasilikelihood*, permitiendo así modelar la variabilidad adicional presente en los datos de *RNA-seq* [13]. La función recibe el objeto DGEList y la matriz de diseño experimental, y devuelve un objeto con el modelo ajustado listo para realizar los contrastes de expresión diferencial.

7.9.5.3 Extracción de resultados

Se utiliza la función glmQLFTest para realizar los contrastes de DE. Esta toma como input el modelo ajustado y la matriz de contrastes generada. Regresa una tabla con los resultados de DE, incluyendo *Log2 fold-change* y FDR ajustado.

7.9.5.4 logCPM

Para los análisis exploratorios y visualizaciones en edgeR, se utiliza una matriz transformada a logCPM (*log Counts Per Million*) por la función `cpm`. Esta métrica normaliza los conteos según el tamaño de biblioteca y aplica una transformación logarítmica, permitiendo reducir parcialmente la heterocedasticidad inherente a los datos [13,24].

7.9.5.5 Implementación

7.10 PCAs




Figure 17: PCA de muestras analizadas con DESeq2 y STAR utilizando los 250 genes con mayor varianza. El análisis se realizó sobre la matriz de expresión normalizada en TPM log2, priorizando genes con mayor variabilidad entre muestras para facilitar la visualización de patrones globales de expresión.




Figure 18: PCA de muestras analizadas con edgeR y STAR utilizando los 500 genes con mayor varianza. El análisis se realizó sobre la matriz de expresión normalizada en logCPM para enfatizar las principales fuentes de variación transcriptómica entre las muestras.




Figure 19: PCA de muestras analizadas con edgeR y STAR utilizando los 250 genes con mayor varianza. El análisis se realizó sobre la matriz de expresión normalizada en logCPM priorizando genes altamente variables para facilitar la identificación de patrones globales de agrupamiento.




Figure 20: PCA de muestras analizadas con edgeR y HISAT2 utilizando los 500 genes con mayor varianza. El análisis se realizó sobre la matriz de expresión normalizada en logCPM para enfatizar las principales fuentes de variación transcriptómica entre muestras.




Figure 21: PCA de muestras analizadas con edgeR y HISAT2 utilizando los 250 genes con mayor varianza. El análisis se realizó sobre la matriz de expresión normalizada en logCPM priorizando genes altamente variables para facilitar la visualización de patrones globales de agrupamiento entre condiciones.

7.11 Heatmaps




Figure 22: Heatmap de los genes diferencialmente expresados más significativos obtenidos con DESeq2 a partir de alineamientos realizados con HISAT2. Se muestran niveles de expresión normalizados en TPM log2 transformados a Z-score por gen. Los patrones generales son concordantes con los obtenidos mediante STAR.

7.12 Volcano plots




Figure 23: Volcano plot de genes diferencialmente expresados obtenidos con DESeq2 a partir de alineamientos realizados con HISAT2. Se muestran los valores de $\log_2$ fold-change frente a $-\log_{10}(\text{FDR})$, utilizando como criterios de significancia $|\log_2\text{FC}| > 0.5$ y $\text{FDR} < 0.05$.

7.13 Enriquecimiento funcional

7.13.1 DAVID

7.13.1.1 Functional Annotation Chart

Por comodidad visual, se cambia el delimitador de , a \t en los archivos descargados.

El código no se muestra en el archivo renderizado pero se encuentra en ./JimenezSotelo_Mateo_ProyectoFin para su consulta.

Table 9: Tabla de términos enriquecidos en DAVID para genes subexpresados con DESeq2 y STAR.

Category	Term	Count	List Total	Pop Hits	Pop Total	P-Value	Benjamini	Fold Enrichment	Bonferroni	FDR	Fisher	Exact	User	Ids
UP_KW_BIOLOGICAL_PROCESS	Apoptosis	2	2	322	5516	0.0584	0.277	17.13	0.344					
UP_SEQ_FEATURE	TRANSMEM:Helical	3	3	2225	8778	0.0642	1.0	3.95	0.914	1.0				
UP_KW_BIOLOGICAL_PROCESS	Host-virus interaction	2	2	436	5516	0.079	0.277	12.0						
GOTERM BP_DIRECT	apoptotic process	2	3	383	8478	0.0883	1.0	14.76	0.997	1.0				

7.13.1.2 Plots David

Se generan los *plots* de los términos y los conteos asociados.

7.13.2 GSEA

Se generan los *plots* de los pathways enriquecidos, mostrando el NES y el FDR asociado.